Bioinformática y Medicina

Grado en Inteligencia Artificial

Plácido Francisco Lizancos Vidal

Parte 2: Problemas y datos sintéticos

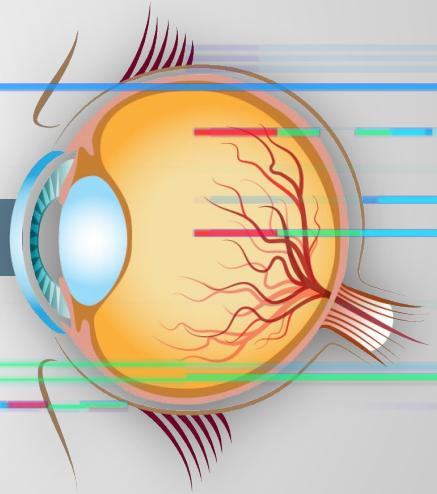

01

Problemas

¿Qué problemas nos solemos encontrar?

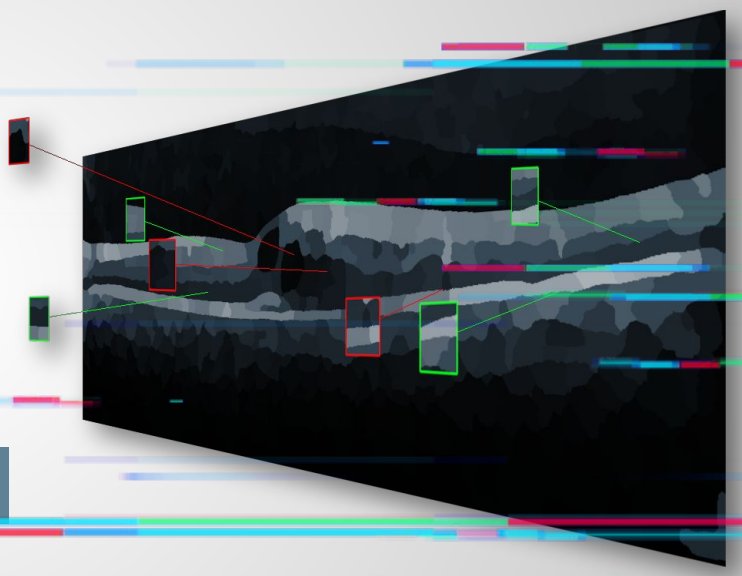

Problemas de los datos médicos

- **Calidad** de los datos
  - Datos **faltantes**
  - Errores de **registro**
    - *Valores imposibles, errores tipográficos, error al copiar y pegar...*
- Sesgos del **dominio**
  - **Desbalanceo** entre clases
  - **Sobrerrepresentación** de grupos
    - *Patologías que afectan más a un sexo, grupo etario, Patologías detectables sólo en etapas avanzadas....*
  - Pruebas **variables**
    - *Patologías que tienen diferentes posibilidades y se realizan pruebas diferentes (p.e. Infecciones por quimioterapia)*
  - **Dataset Shift**
    - *Cambios en las guías clínicas, protocolos...*
- Discrepancia entre **dispositivos de captura**
  - **Escala** de captura diferente
  - **Límites** de medición
  - **Resolución** de captura
    - **Frecuencia** de muestreo
    - **Precisión** de captura
- **Anonimidad** de los datos
- Sesgos **humanos/administrativos**
  - **Selección** de pacientes
    - *Médico decide quién debe ser incluido/medido, UCI...*
  - Desigualdades **poblacionales**
    - *Nivel socioeconómico, recursos del hospital, acceso a servicios de salud, étnicos, culturales...*

¿Qué puedo solucionar con datos sintéticos*?

- **Calidad** de los datos
  - Datos **faltantes**
  - Errores de **registro**
    - *Valores imposibles, errores tipográficos, error al copiar y pegar…*
- Sesgos del **dominio**
  - **Desbalanceo** entre clases
  - **Sobrerrepresentación** de grupos
    - *Patologías que afectan más a un sexo, grupo etario, Patologías detectables sólo en etapas avanzadas….*
  - Pruebas **variables**
    - *Patologías que tienen diferentes posibilidades y se realizan pruebas diferentes (p.e. Infecciones por quimioterapia)*
  - **Dataset Shift**
    - *Cambios en las guías clínicas, protocolos…*
- Discrepancia entre **dispositivos de captura**
  - **Escala** de captura diferente
  - **Límites** de medición
  - **Resolución** de captura
    - **Frecuencia** de muestreo
    - **Precisión** de captura
- **Anonimidad** de los datos
- Sesgos **humanos/administrativos**
  - **Selección** de pacientes
    - *Médico decide quién debe ser incluido/medido, UCI…*
  - Desigualdades **poblacionales**
    - *Nivel socioeconómico, recursos del hospital, acceso a servicios de salud, étnicos, culturales…*

*** probablemente**

02

Problemas 2

¿Qué problemas tienen los datos sintéticos?

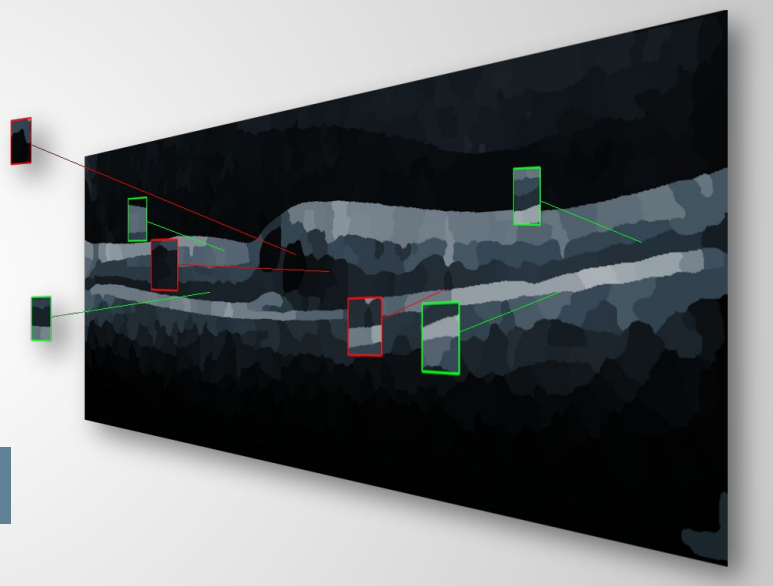

Problemas de los datos sintéticos

Fidelidad:

- ¿Son **suficientemente similares** estadísticamente a los reales?
  - Colapso de moda
  - Eventos espúreos no considerados
  - Pérdida de diversidad

Utilidad:

- ¿Sirven para **análisis/modelado**?
  - Dependencia total de la calidad de los datos fuente:
    - *Garbage in - Garbage out*

Privacidad:

- ¿Hay riesgo de que **información sensible** sea **filtrada**?
  - *Generación explícita de datos de entrenamiento (especialmente espúreos)*
  - *Membership Inference Attacks (MIA)*
  - Hay que buscar un **balance** entre privacidad y fidelidad/utilidad

03

Validación

¿Cómo validamos datos sintéticos?

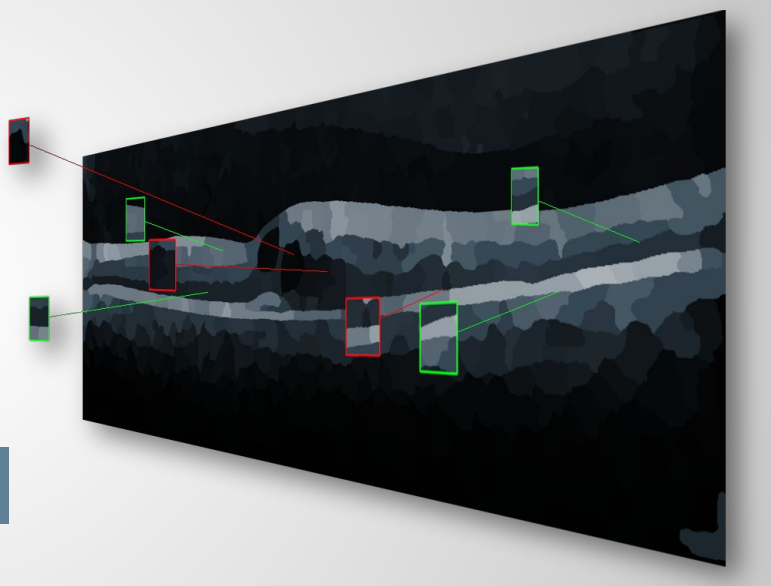

Calidad de los datos sintéticos

Fidelidad: ¿Son **suficientemente similares** estadísticamente a los reales?

- Descriptores de **distribución**:
  - *media, mediana, desv. típica, moda, curtosis, oblicuidad, máximo, mínimo, cuartiles, distancia intercuartílica, análisis de Fourier...*
- Tests **comparativos**:
  - *Kolmogorov-Smirnov, Kernel Density Estimation, Q-Q plots, Distancia Wasserstein, Test Chi-Cuadrado, matrices de correlación, test de información mutua...*

Utilidad: ¿Sirven para nuestro **análisis/modelado**?

- **TR-TR / TS-TR:** Train Real - Test Real / Train Synthetic - Test Real
- **Selectores** de características:
  - Trace Ratio, modelos con selección inherente *(Random Forest, SVM, Relief-F...)*, Wrappers (*Sequential Forward Selection, Recursive Feature Elimination...)*

TR-TR / TS-TR

Train Real - Test Real / Train Synthetic - Test Real

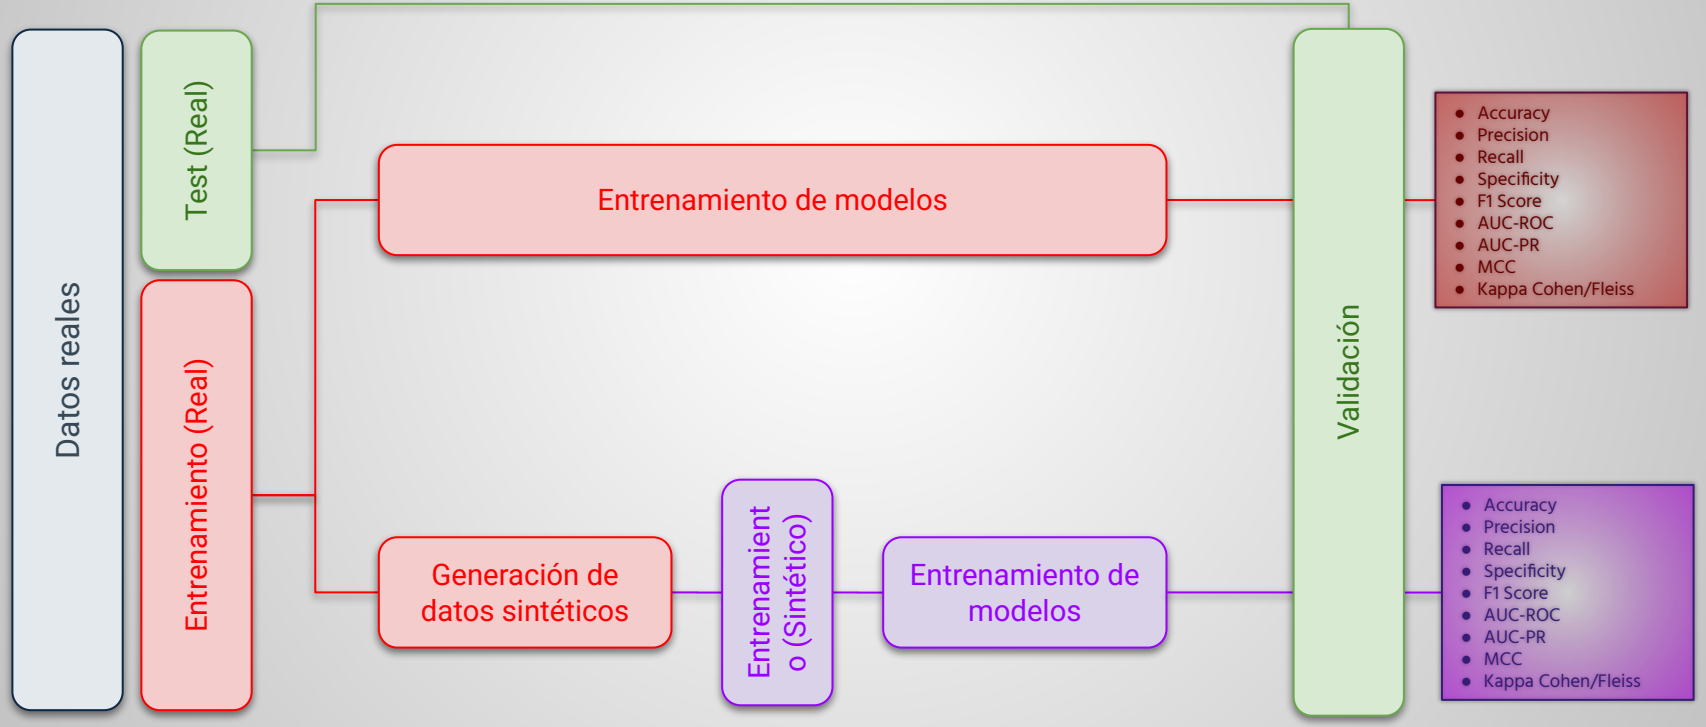

Calidad de los datos sintéticos

Privacidad: ¿Hay riesgo de que información sensible sea **filtrada**?

- **Distance to Closest Record (DCR):**
  - Distancia mínima *(Hamming, euclídea...)* entre un registro sintético y uno real.
- **Nearest Neighbor Distance Ratio (NNDR):**
  - Ratio entre el **DCR** y la segunda/tercera/cuarta... más cercana.
- **Correct Attribution Probability (CAP):**
  - Probabilidad de que un atacante, usando los datos sintéticos y conociendo parte de los datos, acierte el valor real de un atributo.
- **Differential Correct Attribution Probability (DCAP):**
  - Basado en **CAP**, pero se prueban diferentes distribuciones de ruido para intentar combatir estrategias de **privacidad diferencial**.

CAP

Correct Attribution Probability

Real Data

age bracket	gender	political affiliation
20-29	F	?
⋮	⋮	⋮

Synthetic Data

	age bracket	gender	political affiliation
S_0	20-29	F	Indep.
S_1	20-29	F	Dem.
S_2	20-29	F	Dem.
S_3	20-29	F	Rep.
	⋮	⋮	⋮

Equivalence Class

Guess

political affiliation

Dem : 50%

Indep : 25%

Rep : 25%

Anonimidad de los datos

Differential Privacy

- Añadimos **ruido** a las muestras para **limitar**, preservando la significancia estadística del conjunto, la **información individual.**

K-Anonymity

- Un dataset es K-Anónimo si no puedo distinguir la información **cuasi-identificable** de otras **K** muestras.

K-Anonimity

https://utrechtuniversity.github.io/dataprivacyhandbook/k-l-t-anonymity.html

Original dataset

Nr	Age	Sex	City	Disease
1	16	Male	Rotterdam	Viral infection
2	18	Male	Rotterdam	Heart-related
3	19	Male	Rotterdam	Cancer
4	22	Female	Rotterdam	Viral infection
5	22	Male	Zwolle	No illness
6	23	Male	Zwolle	Tuberculosis
7	24	Male	Zwolle	Heart-related
8	25	Female	Utrecht	Cancer
9	26	Female	Rotterdam	Heart-related
10	28	Female	Utrecht	Tuberculosis

2-anonymous dataset

Nr	Age	Sex	City	Disease
1	=< 20	Male	Rotterdam	Viral infection
2	=< 20	Male	Rotterdam	Heart-related
3	=< 20	Male	Rotterdam	Cancer
4	20-30	Female	Rotterdam	Viral infection
5	20-30	Male	Zwolle	No illness
6	20-30	Male	Zwolle	Tuberculosis
7	20-30	Male	Zwolle	Heart-related
8	20-30	Female	Utrecht	Cancer
9	20-30	Female	Rotterdam	Heart-related
10	20-30	Female	Utrecht	Tuberculosis

Colours indicate an ‘equivalence class’ of quasi-identifers

Anonimidad de los datos

Differential Privacy

- Añadimos **ruido** a las muestras para **limitar**, preservando la significancia estadística del conjunto, la **información individual.**

K-Anonymity

- Un dataset es K-Anónimo si no puedo distinguir la información **cuasi-identificable** de otras **K** muestras.

L-Diversity

- Para cada dato sensible, un dataset es L-Diverso si hay al menos **L** diferentes valores para estos datos **sensibles** posibles dentro de **cada combinación** de datos **cuasi-identificables.**

L-Diversity

2-anonymous dataset

Nr	Age	Sex	City	Disease
1	=< 20	Male	Rotterdam	Viral infection
2	=< 20	Male	Rotterdam	Heart-related
3	=< 20	Male	Rotterdam	Cancer
4	20-30	Female	Rotterdam	Viral infection
5	20-30	Male	Zwolle	No illness
6	20-30	Male	Zwolle	Tuberculosis
7	20-30	Male	Zwolle	Heart-related
8	20-30	Female	Utrecht	Cancer
9	20-30	Female	Rotterdam	Viral infection
10	20-30	Female	Utrecht	Cancer

Colours indicate an 'equivalence class' of quasi-identifers

2-anonymous 2-diverse dataset

Nr	Age	Sex	City	Disease
1	=< 20	Male	Rotterdam	Viral infection
2	=< 20	Male	Rotterdam	Heart-related
3	=< 20	Male	Rotterdam	Cancer
4	20-30	Female	•	Viral infection
5	20-30	Male	Zwolle	No illness
6	20-30	Male	Zwolle	Tuberculosis
7	20-30	Male	Zwolle	Heart-related
8	20-30	Female	•	Cancer
9	20-30	Female	•	Viral infection
10	20-30	Female	•	Cancer

Colours indicate an 'equivalence class' of quasi-identifers and sensitive attributes

https://utrechtuniversity.github.io/dataprivacyhandbook/k-l-t-anonymity.html

Anonimidad de los datos

Differential Privacy

- Añadimos **ruido** a las muestras para **limitar**, preservando la significancia estadística del conjunto, la **información individual.**

K-Anonymity

- Un dataset es K-Anónimo si no puedo distinguir la información **cuasi-identificable** de otras **K** muestras.

L-Diversity

- Para cada dato sensible, un dataset es L-Diverso si hay al menos **L** diferentes valores para estos datos **sensibles** posibles dentro de **cada combinación** de datos **cuasi-identificables.**

T-Closeness

- Medida de, para **cada combinación** de datos **cuasi-identificables**, qué porcentaje de la **variabilidad de los datos sensibles** tienen representada.

Anonimidad de los datos

Differential Privacy

- Añadimos **ruido** a las muestras para **limitar**, preservando la significancia estadística del conjunto, la **información individual.**

K-Anonymity

- Un dataset es K-Anónimo si no puedo distinguir la información **cuasi-identificable** de otras **K** muestras.

L-Diversity

- Para cada dato sensible, un dataset es L-Diverso si hay al menos **L** diferentes valores para estos datos **sensibles** posibles dentro de **cada combinación** de datos **cuasi-identificables.**

T-Closeness

- ¿Cuánto **trabajo** tengo que hacer para **obtener la distribución total** si solamente tengo la distribución de datos sensibles **dentro de una combinación de datos cuasi-identificables**?

Anonimidad de los datos

Differential Privacy

- Añadimos **ruido** a las muestras para **limitar**, preservando la significancia estadística del conjunto, la **información individual.**

K-Anonymity

- Un dataset es K-Anónimo si no puedo distinguir la información **cuasi-identificable** de otras **K** muestras.

L-Diversity

- Para cada dato sensible, un dataset es L-Diverso si hay al menos **L** diferentes valores para estos datos **sensibles** posibles dentro de **cada combinación** de datos **cuasi-identificables.**

T-Closeness

- ¿Cómo de **sesgada** está una combinación de datos cuasi-identificables **hacia un dato sensible**?